

# Projeto de Compiladores 2023/24

## Compilador para a linguagem UC

20 de outubro de 2023

Este projeto consiste no desenvolvimento de um compilador para a linguagem UC, que é um subconjunto da linguagem C (de acordo com o padrão C99).

Na linguagem UC é possível usar variáveis e literais do tipo `char`, `short`, `int`, e `double` (todos com sinal). A linguagem UC inclui expressões aritméticas e lógicas, instruções de atribuição, operadores relacionais, e instruções de controlo (`if-else` e `while`). Inclui também funções com os tipos de dados já referidos, sendo a passagem de parâmetros sempre feita por valor. A ausência de parâmetros de entrada ou de valor de retorno é identificada pela palavra-chave `void`.

A função invocada no início de cada programa chama-se `main`, tem valor de retorno do tipo `int` e não recebe parâmetros, sendo que o programa `int main(void) { return 0; }` é um dos mais pequenos possíveis na linguagem UC. Os programas podem ler e escrever caracteres na consola através das funções pré-definidas `getchar()` e `putchar()`, respetivamente.

O significado de um programa na linguagem UC será o mesmo que em C99, assumindo a pré-definição das funções `getchar()` e `putchar()`. Por fim, são aceites comentários nas formas `/* ... */` e `// ...` que deverão ser ignorados. Assim, por exemplo, o programa que se segue imprime na consola os caracteres de A a Z:

```
int main(void) {
    char i = 'A';
    while (i <= 'Z') {
        putchar(i);
        i = i + 1;
    }
    return 0;
}
```

## Metas e avaliação

O projeto está estruturado em quatro metas encadeadas, nas quais o resultado de cada meta é o ponto de partida para a meta seguinte. As datas e as ponderações são as seguintes:

1. Análise lexical (19%) – 20 de outubro de 2023
2. Análise sintática (25%) – 10 de novembro de 2023 (meta de avaliação)
3. Análise semântica (25%) – 24 de novembro de 2023
4. Geração de código (25%) – 15 de dezembro de 2023 (meta de avaliação)

Um relatório com um peso de 6% na avaliação acompanhará a entrega final. Para além disso, a entrega final do trabalho deverá ser feita através do InforEstudante, até ao dia seguinte ao da

Meta 4, e incluir todo o código-fonte produzido no âmbito do projeto (exatamente os mesmos arquivos .zip que tiverem sido colocados no MOOSHAK em cada meta).

O trabalho será verificado no MOOSHAK em cada uma das metas. A classificação final da Meta 1 é obtida em conjunto com a Meta 2 e a classificação final da Meta 3 é obtida em conjunto com a Meta 4. O nome do grupo a registar no MOOSHAK é obrigatoriamente da forma “uc2020123456\_uc2020654321” usando os números de estudante como identificação do grupo na página <http://mooshak.dei.uc.pt/~comp2023> na qual o MOOSHAK está acessível. Será tida em conta apenas a última versão apresentada ao problema A de cada concurso do MOOSHAK para efeitos de avaliação.

## Defesa e grupos

O trabalho será realizado por grupos de dois alunos, preferencialmente inscritos na mesma turma prática. Em casos excecionais, a confirmar com o docente, admite-se trabalhos individuais. A defesa oral do trabalho será realizada em grupo após a entrega da Meta 4. A nota final do projeto é limitada pela soma ponderada das classificações obtidas no MOOSHAK em cada uma das metas e diz respeito à prestação individual na defesa. Assim, a classificação final nunca poderá exceder a classificação obtida no MOOSHAK acrescida da classificação do relatório. Os testes colocados no repositório <https://git.dei.uc.pt/rbarbosa/Comp/tree/master/c> por cada estudante serão contabilizados na avaliação.

## 1 Meta 1 – Analisador lexical

Nesta primeira meta deve ser programado um analisador lexical para a linguagem UC. A programação deve ser feita em linguagem C utilizando a ferramenta *lex*. Os “tokens” a ser considerados pelo compilador deverão estar de acordo com o padrão C99<sup>1</sup> e são apresentados de seguida.

### 1.1 Tokens da linguagem UC

IDENTIFIER: sequências alfanuméricas começadas por uma letra, onde o símbolo “\_” conta como uma letra. Letras maiúsculas e minúsculas são consideradas letras diferentes.

NATURAL: sequências de dígitos de base dez (0–9).

DECIMAL: uma parte inteira seguida de um ponto, opcionalmente seguido de uma parte fracionária e/ou de um expoente; ou um ponto seguido de uma parte fracionária, opcionalmente seguida de um expoente; ou uma parte inteira seguida de um expoente. O expoente consiste numa das letras “e” ou “E” seguida de um número opcionalmente precedido de um dos sinais “+” ou “-”. Tanto a parte inteira como a parte fracionária e o número do expoente consistem em sequências de dígitos de base dez (0–9).

CHRLIT: um único carácter (excepto *newline* ou aspa simples) ou uma “sequência de escape” entre aspas simples. Apenas as sequências de escape `\n`, `\t`, `\\`, `\'`, `\"` e `\ooo` são especificadas pela linguagem, onde `ooo` representa uma sequência de 1 a 3 dígitos entre 0 e 7. A ocorrência de uma sequência de escape inválida ou de mais do que um carácter ou sequência de escape entre aspas simples deve dar origem a um erro lexical.

---

<sup>1</sup>ISO C 1999 Standard – <https://tinyurl.com/c1999standard>

CHAR = char

ELSE = else

WHILE = while

IF = if

INT = int

SHORT = short

DOUBLE = double

RETURN = return

VOID = void

BITWISEAND = "&"

BITWISEOR = "|"

BITWISEXOR = "^"

AND = "&&"

ASSIGN = "="

MUL = "\*"

COMMA = ","

DIV = "/"

EQ = "=="

GE = ">="

GT = ">"

LBRACE = "{"

LE = "<="

LPAR = "("

LT = "<"

MINUS = “-”

MOD = “%”

NE = “!=”

NOT = “!”

OR = “|”

PLUS = “+”

RBRACE = “}”

RPAR = “)”

SEMI = “;”

RESERVED: palavras reservadas da linguagem C não utilizadas em UC, bem como os símbolos “[”, “]”, o operador de incremento (“++”) e o operador de decremento (“--”).

## 1.2 Programação do analisador

O analisador deverá chamar-se *ucompiler*, ler o ficheiro a processar através do *stdin* e, quando invocado com a opção *-l*, deve emitir os tokens e as mensagens de erro para o *stdout* e terminar. Na ausência de qualquer opção deve escrever no *stdout* apenas as mensagens de erro. Caso o ficheiro *first.c* contenha o programa de exemplo apresentado anteriormente, que imprime os caracteres de A a Z, a invocação

```
./ucompiler -l < first.c
```

deverá imprimir a correspondente sequência de tokens no ecrã. Neste caso:

```
INT
IDENTIFIER(main)
LPAR
VOID
RPAR
LBRACE
CHAR
IDENTIFIER(i)
ASSIGN
CHRLIT('A')
SEMI
WHILE
LPAR
...
```

Figura 1: Exemplo de resultado do analisador lexical. O resultado completo está disponível em: <https://git.dei.uc.pt/rbarbosa/Comp/blob/master/c/meta1/first.out>

O analisador deve aceitar (e ignorar) como separador de tokens o espaço em branco (espaços, tabs e mudanças de linha), bem como comentários do tipo */\* ... \*/* e *//... .* Deve ainda detetar a

existência de quaisquer erros lexicais no ficheiro de entrada. Sempre que um token possa admitir mais do que um valor semântico, o valor encontrado deve ser impresso entre parêntesis logo a seguir à categoria do token, como exemplificado acima para IDENTIFIER e CHRLIT.

### 1.3 Tratamento de erros

Caso o ficheiro contenha erros lexicais, o programa deverá imprimir exatamente uma das seguintes mensagens no *stdout*, consoante o caso:

```
"Line <num linha>, column <num coluna>: unrecognized character (<c>)\n"
```

```
"Line <num linha>, column <num coluna>: invalid char constant (<c>)\n"
```

```
"Line <num linha>, column <num coluna>: unterminated comment\n"
```

```
"Line <num linha>, column <num coluna>: unterminated char constant\n"
```

onde <num linha> e <num coluna> devem ser substituídos pelos valores correspondentes ao *início* do token que originou o erro, e <c> deve ser substituído por esse token. O analisador deve recuperar da ocorrência de erros lexicais a partir do *fim* desse token.

### 1.4 Entrega da Meta 1

O ficheiro *lex* a entregar deverá obrigatoriamente identificar os autores num comentário no topo desse ficheiro, contendo o nome e o número de estudante de cada elemento do grupo. Esse ficheiro deverá chamar-se *ucompiler.1* e ser enviado num arquivo de nome *ucompiler.zip* que não deverá ter quaisquer diretorias.

O trabalho deverá ser verificado no MOOSHAK usando o concurso criado para o efeito. Será tida em conta apenas a última versão apresentada ao problema A desse concurso. Os restantes problemas destinam-se a ajudar na verificação do analisador. No entanto, o MOOSHAK não deve ser utilizado como ferramenta de depuração. Os estudantes devem usar e contribuir para o repositório disponível em <https://git.dei.uc.pt/rbarbosa/Comp/tree/master/c> contendo casos de teste. A página do MOOSHAK está indicada no início deste enunciado.

## 2 Meta 2 – Analisador sintático

O analisador sintático deve ser programado em C utilizando as ferramentas `lex` e `yacc`. A gramática que se segue especifica a sintaxe da linguagem UC.

### 2.1 Gramática inicial em notação EBNF

FunctionsAndDeclarations $\rightarrow$ (FunctionDefinition   FunctionDeclaration   Declaration) {FunctionDefinition   FunctionDeclaration   Declaration}
FunctionDefinition $\rightarrow$ TypeSpec FunctionDeclarator FunctionBody
FunctionBody $\rightarrow$ LBRACE [DeclarationsAndStatements] RBRACE
DeclarationsAndStatements $\rightarrow$ Statement DeclarationsAndStatements   Declaration DeclarationsAndStatements   Statement   Declaration
FunctionDeclaration $\rightarrow$ TypeSpec FunctionDeclarator SEMI
FunctionDeclarator $\rightarrow$ IDENTIFIER LPAR ParameterList RPAR
ParameterList $\rightarrow$ ParameterDeclaration {COMMA ParameterDeclaration}
ParameterDeclaration $\rightarrow$ TypeSpec [IDENTIFIER]
Declaration $\rightarrow$ TypeSpec Declarator {COMMA Declarator} SEMI
TypeSpec $\rightarrow$ CHAR   INT   VOID   SHORT   DOUBLE
Declarator $\rightarrow$ IDENTIFIER [ASSIGN Expr]
Statement $\rightarrow$ [Expr] SEMI
Statement $\rightarrow$ LBRACE {Statement} RBRACE
Statement $\rightarrow$ IF LPAR Expr RPAR Statement [ELSE Statement]
Statement $\rightarrow$ WHILE LPAR Expr RPAR Statement
Statement $\rightarrow$ RETURN [Expr] SEMI
Expr $\rightarrow$ Expr (ASSIGN   COMMA) Expr
Expr $\rightarrow$ Expr (PLUS   MINUS   MUL   DIV   MOD) Expr
Expr $\rightarrow$ Expr (OR   AND   BITWISEAND   BITWISEOR   BITWISEXOR) Expr
Expr $\rightarrow$ Expr (EQ   NE   LE   GE   LT   GT) Expr
Expr $\rightarrow$ (PLUS   MINUS   NOT) Expr
Expr $\rightarrow$ IDENTIFIER LPAR [Expr {COMMA Expr}] RPAR
Expr $\rightarrow$ IDENTIFIER   NATURAL   CHRLIT   DECIMAL   LPAR Expr RPAR

Uma vez que a gramática dada é ambígua e é apresentada em notação EBNF, onde [...] representa “opcional” e {...} representa “zero ou mais repetições”, esta deverá ser modificada para permitir a análise sintática ascendente com o yacc. Será necessário ter em conta a precedência e as regras de associação dos operadores, entre outros aspetos, de modo a garantir a compatibilidade entre as linguagens UC e C. Note que o operador COMMA é associativo à esquerda.

## 2.2 Programação do analisador

O analisador deverá chamar-se *ucompiler*, ler o ficheiro a processar através do *stdin* e emitir todos os resultados para o *stdout*. Quando invocado com a opção *-t* deve imprimir a árvore de sintaxe tal como se especifica nas secções que se seguem.

Para manter a compatibilidade com a fase anterior, se o analisador for invocado com a opção *-l* deverá apenas realizar a análise lexical, emitir o resultado para o *stdout* (erros lexicais e os tokens encontrados) e terminar. Se não for passada qualquer opção, o analisador deve apenas escrever no *stdout* as mensagens de erro correspondentes aos erros lexicais e de sintaxe.

## 2.3 Tratamento e recuperação de erros

Caso o ficheiro de entrada contenha erros lexicais, o programa deverá imprimir no *stdout* as mensagens especificadas na Meta 1, e continuar. Caso sejam encontrados erros de sintaxe, o analisador deve imprimir mensagens de erro com o seguinte formato:

“Line <num linha>, column <num coluna>: syntax error: <token>\n”

onde <num linha>, <num coluna> e <token> devem ser substituídos pelos números de linha e de coluna, e pelo valor semântico do token que dá origem ao erro. Isto pode ser conseguido definindo a função:

```
void yyerror (char *s) {  
    printf ("Line_%d, _column_%d:_%s:_%s\n", <num linha>,  
        <num coluna>, s, yytext);  
}
```

A analisador deve ainda incluir recuperação local de erros de sintaxe através da adição das seguintes regras de erro à gramática (ou de outras com o mesmo efeito dependendo das alterações que a gramática dada vier a sofrer):

Declaration → error SEMI  
Statement → error SEMI  
Statement → LBRACE error RBRACE  
Expression → IDENTIFIER LPAR error RPAR  
Expression → LPAR error RPAR

## 2.4 Árvore de sintaxe abstrata (AST)

Caso seja feita a seguinte invocação:

```
./ucompiler -t < first.c
```

deverá gerar a árvore de sintaxe abstrata correspondente, e imprimi-la no stdout de acordo com a especificação que se segue. A árvore de sintaxe abstrata só deverá ser impressa se não houver erros de sintaxe. Caso haja erros lexicais que não causem também erros de sintaxe, a árvore deverá ser impressa imediatamente a seguir às correspondentes mensagens de erro.

As árvores de sintaxe abstrata geradas durante a análise sintática devem incluir apenas nós dos tipos indicados abaixo. Entre parêntesis à frente de cada nó indica-se o número de filhos desse nó e, onde necessário, também o tipo de filhos.

### Nó raiz

Program ( $\geq 1$ ) (<variable and/or function declarations>)

### Declaração de variáveis

Declaration ( $\geq 2$ ) (<typespec> Identifier)

### Declaração/definição de Funções

FuncDeclaration (3) (<typespec> Identifier ParamList)

FuncDefinition (4) (<typespec> Identifier ParamList FuncBody)

ParamList ( $\geq 1$ ) (ParamDeclaration)

FuncBody ( $\geq 0$ ) (<declarations> | <statements>)

ParamDeclaration( $\geq 1$ ) (<typespec> [Identifier])

### Statements

StatList( $\geq 2$ ) If(3) While(2) Return(1)

### Operadores

Or(2) And(2) Eq(2) Ne(2) Lt(2) Gt(2) Le(2) Ge(2) Add(2) Sub(2) Mul(2) Div(2) Mod(2)  
Not(1) Minus(1) Plus(1) Store(2) Comma(2) Call( $\geq 1$ ) BitWiseAnd(2) BitWiseXor(2)  
BitWiseOr(2)

### Terminais

Char, ChrLit, Identifier, Int, Short, Natural, Double, Decimal, Void

### Especial

Null (na ausência de um nó filho obrigatório)

**Nota:** Não deverão ser gerados nós supérfluos, nomeadamente StatList que contenham menos de dois *statements*. Os nós Program, ParamList e FuncBody não deverão ser considerados redundantes mesmo que tenham menos de dois nós filhos.

A Figura 3 exemplifica a impressão da árvore de sintaxe abstrata do programa apresentado na primeira página.



```
Program
..FuncDefinition
...Int
....Identifier(main)
....ParamList
.....ParamDeclaration
.....Void
...FuncBody
...
```

Figura 2: Exemplo de output do analisador sintático. O output completo está disponível em <https://git.dei.uc.pt/rbarbosa/Comp/blob/master/c/meta2/first.out>

## 2.5 Desenvolvimento do analisador

Sugere-se que desenvolva o analisador de forma faseada. Deverá começar por re-escrever a gramática acima apresentada para o yacc de modo a permitir a deteção de eventuais erros de sintaxe. Após terminada esta fase, e já com garantia que a gramática está correta, deverá focar-se no desenvolvimento do código necessário para a construção da árvore de sintaxe abstrata e a sua impressão para o stdout. O relatório final deverá descrever as opções tomadas na escrita da gramática, pelo que se recomenda agora a documentação dessa parte.

Para promover uma boa divisão de tarefas entre elementos do grupo, sugere-se que comecem por analisar produções diferentes. Observando o não-terminal `FunctionsAndDeclarations`, um elemento começaria por `FunctionsAndDeclarations`  $\rightarrow$  `FunctionDefinition` {`FunctionDefinition`} enquanto o outro começaria por `FunctionsAndDeclarations`  $\rightarrow$  `Declaration` {`Declaration`}. Teriam de coordenar o trabalho a partir do momento em que chegassem a não-terminais comuns na gramática.

Deverá ter em atenção que toda a memória alocada durante a execução do analisador deve ser libertada antes deste terminar, devendo ter em conta as situações em que a construção da AST é interrompida por erros de sintaxe.

## 2.6 Entrega da Meta 2

O ficheiro *lex* entregue deverá obrigatoriamente listar os autores num comentário colocado no topo desse ficheiro, contendo o nome e o número de estudante de cada membro do grupo. Os ficheiros *lex* e *yacc* a entregar deverão chamar-se *ucompiler.l* e *ucompiler.y* e ser colocados num único arquivo com o nome *ucompiler.zip* juntamente com quaisquer outros ficheiros necessários para compilar o analisador.

O trabalho deverá ser avaliado no MOOSHAK, usando o concurso criado especificamente para o efeito e cuja página está acima indicada. Para efeitos de avaliação, será tida em conta apenas a última versão apresentada ao problema A desse concurso. Os restantes problemas destinam-se a ajudar na validação do analisador, nomeadamente no que respeita à deteção de erros de sintaxe e à construção da árvore de sintaxe abstrata. No entanto, o MOOSHAK não deve ser utilizado como ferramenta de depuração. Os estudantes deverão usar e contribuir para o repositório disponível em <https://git.dei.uc.pt/rbarbosa/Comp/tree/master/c> contendo casos de teste.

### 3 Meta 3 – Analisador semântico

O analisador semântico deve ser programado em C tendo por base o analisador sintático desenvolvido na meta anterior com as ferramentas `lex` e `yacc`. O analisador deverá chamar-se `ucompiler`, ler o ficheiro a processar através do `stdin` e detetar a ocorrência de quaisquer erros (lexicais, sintáticos ou semânticos) no ficheiro de entrada. Considere a invocação

```
./ucompiler < first.c
```

deverá levar o analisador a proceder à análise lexical e sintática do programa e, caso este seja válido, proceder à análise semântica.

Por uma questão de compatibilidade com a fase anterior, se o analisador for invocado com a opção `-t`, deverá realizar *apenas* a análise sintática, e emitir o resultado para o `stdout` (erros lexicais e/ou sintáticos e a árvore de sintaxe abstrata se não houver erros de sintaxe) e terminar *sem* proceder à análise semântica. A opção `-l` também deverá manter a funcionalidade previamente especificada.

Sendo o programa sintaticamente válido, a invocação

```
./ucompiler -s < first.c
```

deve fazer com que o analisador imprima no `stdout` a(s) tabela(s) de símbolos correspondente(s) seguida(s) de uma linha em branco e da árvore de sintaxe abstrata anotada com os tipos das variáveis, funções e expressões, de acordo com a especificação que se segue.

#### 3.1 Tabelas de símbolos

Durante a análise semântica, deve ser construída uma tabela de símbolos global contendo os identificadores das funções pré-definidas `getchar`, `putchar`, bem como os identificadores das variáveis e/ou funções declaradas e/ou definidas no programa. Por sua vez, as tabelas correspondentes às funções definidas no programa irão conter a string “return” (usada para representar o valor de retorno) e os identificadores dos respetivos parâmetros formais e variáveis locais.

Para o programa de exemplo dado, as tabelas de símbolos a imprimir são as que se seguem. O formato das linhas é “Name\tType[\tparam]”, onde [] significa *opcional*.

```
==== Global Symbol Table ====
putchar int(int)
getchar int(void)
main    int(void)

==== Function main Symbol Table ====
return  int
i       char
```

Os símbolos (e as tabelas) devem ser apresentados por ordem de primeira declaração ou definição no programa fonte. Em particular, caso uma função `f1` seja declarada antes e definida depois de outra função `f2`, a tabela da função `f1` deverá ser impressa antes da tabela da função `f2`. Caso uma função seja declarada mas não seja definida, o seu nome e tipo devem aparecer na tabela de símbolos global, mas não deve ser impressa qualquer tabela para essa função. É o caso das funções pré-definidas `getchar` e `putchar`. No essencial, a notação para os tipos segue as convenções do C. Deve ser deixada uma linha em branco entre tabelas consecutivas, e entre as tabelas e a árvore de sintaxe abstrata anotada.

## 3.2 Árvore de sintaxe anotada

Para o programa dado, a árvore de sintaxe abstrata anotada a imprimir a seguir às tabelas de símbolos com a opção -s seria a seguinte:

```
Program
..FuncDefinition
....Int
....Identifier(main)
....ParamList
.....ParamDeclaration
.....Void
....FuncBody
.....Declaration
.....Char
.....Identifier(i)
.....ChrLit('A') - int
.....While
.....Le - int
.....Identifier(i) - char
.....ChrLit('Z') - int
...
```

Figura 3: Exemplo de output do analisador semântico. O output completo está disponível em <https://git.dei.uc.pt/rbarbosa/Comp/blob/master/c/meta3/first.out>

**Deverão ser anotados apenas os nós correspondentes a expressões.** Declarações ou statements que não sejam expressões não devem ser anotados.

## 3.3 Tratamento de erros semânticos

Eventuais erros de semântica deverão ser detetados e reportados no stdout de acordo com o catálogo de erros listado de seguida, onde cada mensagem deve ser antecidida pelo prefixo “Line <linha>, column <coluna>: ” e terminada com um caractere de fim de linha.

```
Conflicting types (got <type>, expected <type>)
Invalid use of void type in declaration
Lvalue required
Operator <token> cannot be applied to type <type>
Operator <token> cannot be applied to types <type>, <type>
Symbol <token> already defined
Symbol <token> is not a function
Unknown symbol <token>
Wrong number of arguments to function <token> (got <number>,
required <number>)
```

Caso seja detetado algum erro durante a análise semântica do programa, **o analisador deverá imprimir a mensagem de erro apropriada e continuar, atribuindo o pseudo-tipo** undef a quaisquer símbolos desconhecidos e aos resultados de operações cujo tipo não possa ser determinado devido aos seus operandos (inválidos), o que pode dar origem a novos erros semânticos. Os tipos de dados (<type>) a reportar nas mensagens de erro deverão ser os mesmos usados

na impressão das tabelas de símbolos, e todos os tokens (<token>) deverão ser apresentados tal como aparecem no código fonte. Os números de linha e coluna a reportar dizem respeito ao primeiro caractere dos seguintes tokens:

- O identificador que dá origem ao erro,
- O operador cujos argumentos são de tipos incompatíveis (conversões “Warnings” em C, devem dar origem a erros de incompatibilidade de tipos),
- O operador ou o identificador da função invocada correspondente à raiz da AST da expressão que é incompatível com a forma como é usada (considerar que o tipo esperado pelas condições das construções `if` e `while` é `int`, embora alguns outros tipos também sejam aceitáveis),
- O identificador da função invocada quando o número de parâmetros estiver errado,
- O primeiro token `void` que torne inválida uma declaração ou definição.

A impressão das tabelas de símbolos e da AST anotada (se for o caso) deve ser feita depois da impressão de todas as mensagens de erro.

### 3.4 Programação do analisador

Sugere-se que o desenvolvimento do analisador seja efetuado em três fases. A primeira deverá consistir na construção das tabelas de símbolos e a sua impressão, a segunda na verificação de tipos e anotação da AST, e a terceira no tratamento de erros semânticos.

### 3.5 Entrega da Meta 3

O trabalho deverá ser avaliado no MOOSHAK, usando o concurso criado especificamente para o efeito e cuja página está acima indicada. Para efeitos de avaliação, será tida em conta apenas a última submissão ao problema A desse concurso. Os restantes problemas destinam-se a ajudar na validação do analisador, nomeadamente no que respeita à deteção de erros de semântica e à construção da árvore de sintaxe abstrata anotada, de acordo com a estratégia de desenvolvimento proposta. No entanto, o MOOSHAK não deve ser utilizado como ferramenta de depuração. Os estudantes deverão usar e contribuir para o repositório disponível em <https://git.dei.uc.pt/rbarbosa/Comp/tree/master/c> contendo casos de teste.

Os ficheiros `lex` e `yacc` a apresentar deverão chamar-se `ucompiler.l` e `ucompiler.y` e ser colocados juntamente com quaisquer ficheiros adicionais necessários à compilação do analisador num único ficheiro `.zip` com o nome `ucompiler.zip`. O ficheiro `.zip` não deve conter quaisquer diretorias. Note que deverá *listar os autores em comentário* no ficheiro `ucompiler.l`.

## 4 Meta 4 – Geração de código

O gerador de código deve ser programado em C utilizando as ferramentas `lex` e `yacc` a partir do código desenvolvido nas metas anteriores. Deverá chamar-se `ucompiler`, como anteriormente, ler do `stdin` o programa a compilar e emitir para o `stdout` um programa na representação intermédia do LLVM que tenha a mesma funcionalidade que o programa de entrada. Por exemplo, a invocação:

```
./ucompiler < first.c > first.ll
```

deverá processar e analisar o programa `first.c` e escrever o código LLVM IR correspondente no ficheiro `first.ll`. Este poderá ser executado diretamente na linha de comandos:

```
lli first.ll
```

ou compilado e ligado com:

```
llc first.ll  
cc -o first first.s
```

podendo o executável resultante ser invocado a partir da linha de comandos:

```
./first
```

Ao executar o programa `first` deverá ser impresso no ecrã o seguinte:

```
ABCDEFGHIJKLMNOPQRSTUVWXYZ
```

Para efeitos de verificação, o compilador deve fornecer ainda as seguintes opções especificadas nas metas anteriores:

- `-l` : executa a análise lexical, reportando os tokens encontrados e eventuais erros lexicais, e termina.
- `-t` : executa a análise sintática, reportando eventuais erros lexicais/sintáticos, imprime a árvore de sintaxe abstrata construída durante a análise sintática do programa (se não houver erros sintáticos) e termina.
- `-s` : executa a análise semântica (se não houver erros sintáticos), reportando eventuais erros semânticos, imprime o conteúdo da(s) tabela(s) de símbolos e a árvore de sintaxe abstrata anotada e termina.

Só deverá ser gerado código LLVM IR caso não haja erros de qualquer tipo nem sejam passadas quaisquer opções na linha de comandos. Caso seja passada uma opção desconhecida, o compilador deve comportar-se tal como se não recebesse qualquer opção (emitindo código).

### 4.1 Programação do gerador de código

As funções pré-definidas `putchar` e `getchar` devem ser simplesmente declaradas no código LLVM, sendo isto suficiente para que sejam utilizadas as funções presentes na biblioteca standard da linguagem C.

Os tipos de dados `int`, `short` e `char` da linguagem UC deverão ser codificados através do tipo `i32` da representação intermédia LLVM e o tipo `double` deverá ser codificado através do tipo LLVM IR `double`.

## 4.2 Entrega da Meta 4

O trabalho deverá ser avaliado no MOOSHAK, usando o concurso criado especificamente para o efeito e cuja página está acima indicada. Para efeitos de avaliação, será tida em conta apenas a última submissão ao problema A desse concurso. Os restantes problemas destinam-se a ajudar na validação do analisador. No entanto, o MOOSHAK não deve ser utilizado como ferramenta de depuração. Os estudantes deverão usar e contribuir para o repositório disponível em <https://git.dei.uc.pt/rbarbosa/Comp/tree/master/c> contendo casos de teste.

Os ficheiros `lex` e `yacc` a apresentar deverão chamar-se `ucompiler.l` e `ucompiler.y` e ser colocados juntamente com quaisquer ficheiros adicionais necessários à compilação do analisador num único ficheiro `.zip` com o nome `ucompiler.zip`. O ficheiro `.zip` não deve conter quaisquer diretorias. Note que deverá *listar os autores em comentário* no ficheiro `ucompiler.l`.

## 5 Entrega final e relatório

A entrega final do projeto será feita no Infoestudante até ao dia seguinte ao da Meta 4, e deve incluir todo o código-fonte produzido no âmbito do projeto: precisamente os quatro arquivos `.zip` que tiverem sido apresentados no MOOSHAK em cada meta. Os ficheiros `.zip` correspondentes a cada submissão devem chamar-se `1.zip`, `2.zip`, `3.zip`, `4.zip`, para as versões apresentadas às Metas 1, 2, 3 e 4, respetivamente.

Em todas as entregas no MOOSHAK o ficheiro `ucompiler.l` deve identificar os autores num comentário acrescentado ao topo do ficheiro. Sem a identificação dos autores de cada trabalho não será possível atribuir a respetiva classificação.

O relatório final (que poderá ser enviado em ficheiro de texto simples ou markdown) terá três secções limitadas a 1200 palavras (400 palavras por cada secção), sendo que deverá documentar concisamente as opções técnicas relativas

- (i) à gramática re-escrita,
- (ii) aos algoritmos e estruturas de dados da AST e da tabela de símbolos, e
- (iii) à geração de código.